

Лабораторная работа №1: Анализ чувствительности линейной регрессии

Тиганов В.И., ИСУ 467701, гр.Ж3112
Вагин А.А., ИСУ 465339, гр.Ж3112
Практический поток 1.3

12 марта 2025 г.

1 Введение

В данном отчете проводится анализ чувствительности модели линейной регрессии к ошибкам округления и исследуется сходимость вычисленных и исходных данных. Анализ основан на наборе данных `housing.csv`, с использованием различных конфигураций полиномиальных признаков и масштабирования. Цель работы — изучить влияние числа обусловленности матрицы признаков на точность модели и выявить оптимальные параметры для построения устойчивой регрессионной модели.

2 Методология

Набор данных разделен на обучающую и тестовую выборки с следующими параметрами:

- Размер тестовой выборки: 0.23
- Параметр случайности: 45

К данным применяются полиномиальные признаки (степени 1, 2 и 3) и масштабирование (StandardScaler), после чего обучается модель линейной регрессии. Для оценки качества модели используются следующие метрики:

- Средняя абсолютная ошибка (MAE) на обучающей и тестовой выборках
- Число обусловленности матрицы $X_{train}^T \times X_{train}$ для оценки численной устойчивости

3 Результаты

Результаты экспериментов представлены в следующей таблице:

№ эксперимента	Масштабирование	Степень полинома	MAE обучения	MAE теста	Число обусл.
1	Нет	1	3.22	3.68	7.28×10^7
2	Нет	2	1.80	2.56	5.46×10^{15}
3	Нет	3	0.60	15.45	8.48×10^{30}
4	Да	1	22.46	22.85	9.08×10^1
5	Да	2	22.46	22.38	2.11×10^8
6	Да	3	22.46	28.05	2.60×10^{18}

Таблица 1: Результаты экспериментов с различными параметрами

4 Анализ




Рис. 1: Зависимость числа обусловленности от MAE для обучающей (синий) и тестовой (оранжевый) выборок. Логарифмическая шкала по оси Y.

Анализ результатов (Таблица 1 и Рисунок 1) позволяет сделать следующие выводы:

1. Влияние масштабирования:

- Без масштабирования модель показывает лучшую точность на низких степенях полинома (MAE 3.22 против 22.46 при степени 1)
- Однако при увеличении степени полинома без масштабирования возникает проблема численной неустойчивости (число обусловленности достигает 10^{30})

2. Влияние степени полинома:

- Без масштабирования увеличение степени приводит к резкому росту числа обусловленности и переобучению (MAE обучения 0.60 vs MAE теста 15.45 при степени 3)
- С масштабированием ситуация более стабильна, но точность модели существенно ниже

3. Оптимальная конфигурация:

- Наилучший баланс между точностью и устойчивостью достигается при степени полинома 2 без масштабирования (MAE теста 2.56)
- Однако при этом число обусловленности остается высоким (5.46×10^{15}), что может вызывать проблемы при использовании разных реализаций алгоритмов

5 Заключение

Проведенный анализ позволяет сделать следующие выводы:

1. Масштабирование данных существенно снижает число обусловленности, но в данном случае приводит к значительному ухудшению точности модели. Это может быть связано с особенностями набора данных.
2. Увеличение степени полинома без масштабирования приводит к катастрофическому росту числа обусловленности и переобучению, несмотря на высокую точность на обучающей выборке.
3. Для данного набора данных оптимальным выбором является:

- Использование полинома 2-й степени
- Отказ от масштабирования (в данном конкретном случае)
- Необходимость дополнительной регуляризации для улучшения устойчивости

4. Для промышленного применения рекомендуется:

- Провести дополнительное исследование с другими методами масштабирования
- Рассмотреть возможность использования регуляризованных моделей (Ridge, Lasso)
- Провести анализ мультиколлинеарности признаков

Перспективы дальнейшего исследования включают анализ влияния различных методов регуляризации на устойчивость модели и точность прогнозов, а также сравнение с другими алгоритмами регрессии.